

Ouvidoria Inteligente: Triagem Semântica de Manifestações Cidadãs

Relatório do Desafio Prático - NLP Aplicado

1. Objetivo e metodologia

O projeto desenvolve uma solução de Processamento de Linguagem Natural (NLP) para apoiar a análise de manifestações cidadãs. Foi utilizada uma base sintética com 40 manifestações anonimizadas, distribuídas entre infraestrutura, saúde, segurança, educação e meio ambiente, incluindo duplicatas semânticas e textos longos. Foram avaliadas representações Bag-of-Words (BoW), TF-IDF e sentence embeddings, utilizando similaridade de cosseno. Também foram realizados experimentos de detecção de duplicatas, chunking e redução dimensional, além da implementação de uma interface em Streamlit.

2. Comparação das representações

Par	BoW	TF-IDF	Embeddings
M003 x M017	0,356	0,239	0,732
M008 x M022	0,467	0,371	0,827
M008 x M031	0,150	0,046	0,154

Os embeddings apresentaram maior similaridade nos pares semanticamente relacionados M003 x M017 e M008 x M022, mesmo com diferenças de vocabulário. BoW e TF-IDF mostraram maior dependência da sobreposição lexical. No par M008 x M031, de assuntos distintos, as três abordagens apresentaram baixa similaridade. Assim, embeddings se mostraram mais adequados ao objetivo de busca semântica, embora possuam maior custo computacional e menor interpretabilidade direta.

3. Detecção de duplicatas

A função **detectar_duplicatas(textos, limiar=0.85)** foi implementada com embeddings e similaridade de cosseno. Com o limiar padrão de 0,85, foram identificadas 2 das 6 duplicatas conhecidas, sem falsos positivos e com 4 falsos negativos. Também foram testados outros limiares para avaliar o equilíbrio entre recuperação e associações incorretas.

Limiar	Pares	VP	FP	FN
0,70	18	6	12	0
0,75	9	5	4	1
0,80	6	5	1	1
0,85	2	2	0	4
0,90	1	1	0	5

Entre os valores testados, 0,80 apresentou o melhor equilíbrio nesta base: 5 verdadeiros positivos, 1 falso positivo e 1 falso negativo. O falso positivo foi M029 x M034 e o falso negativo foi M003 x M017. O resultado evidencia que o limiar deve ser ajustado às características da base e ao custo de cada tipo de erro.

4. Chunking e espaço vetorial

As cinco manifestações mais longas foram processadas com **RecursiveCharacterTextSplitter**. Foram comparadas duas configurações: `chunk_size=200` com `chunk_overlap=40` e `chunk_size=350` com `chunk_overlap=70`. A primeira produziu de 5 a 7 chunks por manifestação, enquanto a segunda produziu de 2 a 3. Chunks menores oferecem maior granularidade; chunks maiores preservam trechos mais extensos. O overlap ajuda a manter contexto entre segmentos, ao custo de repetição de conteúdo.

Os embeddings dos chunks da primeira configuração foram projetados em duas dimensões com PCA. Alguns segmentos da mesma manifestação permaneceram próximos, mas não formaram grupos totalmente separados, havendo também sobreposição entre manifestações. Isso indica que diferentes trechos podem compartilhar características semânticas.

5. Aplicação Streamlit

A aplicação **app_ouvidoria.py** reúne os experimentos em uma interface com quatro abas. A Busca Semântica retorna os resultados mais próximos com score e indicação visual; a Base de Manifestações exibe os 40 registros e gera a matriz de similaridade; o Espaço Vetorial permite alternar entre PCA e t-SNE e visualizar os pontos por categoria oficial; e a aba Chunking permite inserir textos longos, configurar tamanho e overlap, visualizar os segmentos e seus embeddings. A barra lateral permite selecionar o modelo de embeddings e configurar o Top-K.

6. Conclusão

Os experimentos mostram que embeddings são mais apropriados para identificar proximidade semântica quando textos descrevem problemas semelhantes com palavras diferentes. A detecção de duplicatas mostrou sensibilidade à escolha do limiar, enquanto o chunking demonstrou o compromisso entre granularidade, preservação de contexto e repetição.